

CURS#5

II. Sisteme de ecuații liniare

- (a) Rafinarea iterativă (metoda corecției reziduale). Vector eroare absolută, vector eroare reziduală.
- (b) Metode iterative staționare:
 - (i) descompunerea aditivă a matricei sistemului;
 - (ii) metoda Jacobi;
 - (iii) metoda Gauss-Seidel.
- (c) Norme matriciale induse de o normă vectorială. Număr de condiționare al unei matrice.
- (d) Analiza stabilității sistemelor de ecuații liniare.

II. SISTEME DE ECUATII LINIARE

PROBLEMA :

Date $A = (a_{i,j})$ $\underset{i,j=1,n}{\text{matrice}} \in M_n(\mathbb{R})$ inversabilă

și $b = (b_i)$ $\underset{i=1,n}{\text{vector}} \in \mathbb{R}^n$, să se determine

$x = (x_i)$ $\underset{i=1,n}{\text{vector}} \in \mathbb{R}^n$ astfel

$$\boxed{Ax = b} \quad (1)$$

sau, echivalent :

$$\begin{cases} a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n = b_1 \\ a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n = b_2 \\ \vdots \\ a_{n1}x_1 + a_{n2}x_2 + \dots + a_{nn}x_n = b_n \end{cases}$$

Să se determine o soluție numerică (approximativ) $x \in \mathbb{R}^n$ pt (1).

1) RAFINAREA ITERATIVĂ

- Datele problemei :

$A \in M_n(\mathbb{R})$ matrice inversabilă;
 $b \in \mathbb{R}^n$.

- $\underline{x}^* := A^{-1} \underline{b}$ soluția exactă a sistemului liniar

$$A \underline{x} = \underline{b} \quad (1)$$

- $\underline{x} \in \mathbb{R}^n$ o soluție numerică a sistemului, obținută printr-o metodă directă, eg. metodele de eliminare Gauss, factorizările LU, PLU, Cholesky.

DEFINIE:

Se vectorul eroare (absolută) în $\underline{x} \in \mathbb{R}^n$

$$e := \underline{x}^* - \underline{x} \in \mathbb{R}^n \quad (2)$$

DEFINIȚIE:

Se numește reziduu (eroare reziduală)

în x :

$$\boxed{r := b - Ax \in \mathbb{R}^n} \quad (3)$$

OBSERVAȚII:

1) Vectorii \underline{r} și \underline{r} satisfac sistemul

$$\boxed{A\underline{r} = \underline{r}} \quad (4)$$

Dem:

$$A\underline{r} = A(\underline{x}^* - \underline{x}) = A\underline{x}^* - A\underline{x} = b - Ax = r$$

□

2) Rafinarea iterativă: o tehnică de
îmbunătățire iterativă a acurateții
soluției numérice a sistemului (1),
obținută printr-o metodă direcță,

prin recunoașterea succesiivă a soluț. (2).

Algoritm (rafinarea iterativă):

Date: $A \in \mathbb{M}_n(\mathbb{R})$ inversabilă

$$\underline{b} \in \mathbb{R}^n$$

$\varepsilon > 0$ toleranță / acuratețea dorită

$ITMAX$ nr. maxim de iterări

$k=0$: $\underline{x}^{(k)} := \text{MetDirecto}(A, \underline{b})$;

$$\underline{r}^{(k)} := \underline{b} - A\underline{x}^{(k)}$$

white ($\|\underline{r}^{(k)}\| > \varepsilon \wedge k < ITMAX$)

$\underline{z} := \text{MetDirecto}(A, \underline{r}^{(k)})$

$$\underline{x}^{(k)} := \underline{x}^{(k)} + \underline{z}$$

$$\underline{r}^{(k)} := \underline{b} - A\underline{x}^{(k)}$$

$$k = k + 1$$

end

2) METODE ITERATIVE STATIONARE

- Datele problemei :

$A \in M_n(\mathbb{R})$ matrice inversabilă;
 $\underline{b} \in \mathbb{R}^n$.

- $\underline{x}^* := A^{-1} \underline{b}$ soluția exactă a sistemului liniar

$$\boxed{A \underline{x} = \underline{b}} \quad (1)$$

IDEA: Descompunerea aditivă

(matrix splitting) a matricei A :

$$A = N - P$$

$N \in M_n(\mathbb{R})$ inversabilă (usor); (2)

$P \in M_n(\mathbb{R})$ asigură convergență

în (1) și (2), obținem:

$$N \underline{x}^* = P \underline{x}^* + \underline{b} \Rightarrow \boxed{\underline{x}^* = N^{-1} P \underline{x}^* + N^{-1} \underline{b}} \quad (3)$$

În urmă, considerăm următoarea
metodă iterativă:

$$\boxed{\begin{aligned} x^{(0)} &\in \mathbb{R}^n \\ x^{(k)} &= N^{-1} P x^{(k-1)} + N^{-1} b, \quad k \geq 1 \end{aligned}} \quad (4)$$

Din (4) și (2), rezultă:

$$\begin{aligned} x^{(k)} &= N^{-1} P x^{(k-1)} + N^{-1} b \\ &= N^{-1} (N - A) x^{(k-1)} + N^{-1} b \\ &= N^{-1} N x^{(k-1)} + N^{-1} b - N^{-1} A x^{(k-1)} \\ &= x^{(k-1)} + N^{-1} (b - A x^{(k-1)}) = x^{(k-1)} + N^{-1} r \\ &= r^{(k-1)} \end{aligned}$$

Metoda iterativă (4) se poate scrie ca

$$\begin{aligned} k=0: \quad x^{(0)} &\in \mathbb{R}^n \\ r^{(0)} &:= b - A x^{(0)} \quad (5) \\ k \geq 1: \quad s x^{(k-1)} &: N(s x^{(k-1)}) = r^{(k-1)} \\ x^{(k)} &:= x^{(k-1)} + \boxed{s x^{(k-1)}} \quad \begin{array}{l} \text{coracie} \\ \text{a lui } x^{(k)} \end{array} \\ k=k+1 &\rightarrow \text{repete} \quad k \geq 1 \end{aligned}$$

ANALIZA SEMIN:

$$\begin{aligned}
 \mathbf{r}^{(k)} &:= \mathbf{x}^* - \mathbf{x}^{(k)} \\
 &= \mathbf{N}^{-1} \mathbf{P} \mathbf{x}^* + \mathbf{N}^{-1} \mathbf{b} - (\mathbf{N}^{-1} \mathbf{P} \mathbf{x}^{(k-1)} + \mathbf{N}^{-1} \mathbf{b}) \\
 &= \mathbf{N}^{-1} \mathbf{P} \mathbf{x}^* - \mathbf{N}^{-1} \mathbf{P} \mathbf{x}^{(k-1)} \\
 &= \underbrace{(\mathbf{N}^{-1} \mathbf{P})}_{\{M\}} \underbrace{(\mathbf{x}^* - \mathbf{x}^{(k-1)})}_{\{e^{(k-1)}\}} = M e^{(k-1)} = \\
 &=: M = e^{(k-1)}
 \end{aligned}$$

$$= M^2 e^{(k-2)} = \dots = M e^{(0)}, \quad \forall k \geq 0$$

Am obținut:

$$\boxed{\mathbf{r}^{(k)} = M e^{(k)}, \quad k \geq 0; \quad M := \mathbf{N}^{-1} \mathbf{P}} \quad (6)$$

- Vrem $e^{(k)} \xrightarrow{k \rightarrow \infty} 0 \in \mathbb{R}^n$, deci este suficient ca
- $M e^{(k)} \xrightarrow{k \rightarrow \infty} 0 \in \mathbb{R}^n$;
 - $\|M\| < 1$, cu normă matricială inducă de o normă vectorială.

CASURI PRACTICARE:

$$A = \begin{bmatrix} a_{11} & & & \\ & a_{22} & & \\ & & \ddots & \\ & & & a_{nn} \end{bmatrix} \stackrel{\text{not}}{=} L + D + U$$
$$D := \text{diag}(a_{11}, a_{22}, \dots, a_{nn})$$

(1) METODA JACOBI:

$$\begin{cases} N = D \\ P = -(L + U) \end{cases}$$

(2) METODA GAUSS-SEIDEL:

$$\begin{cases} N = L + D \\ P = -U \end{cases}$$

Ex: Determinati explicit metodele
iterative statioare Jacobi, resp.
Gauss - Seidel.

3) NORME MATERICIALE INDUSE DE NORME VECTORIALE

DEFINITIE :

Fie $\|\cdot\|$ o normă vectorială pe \mathbb{R}^n .

Să normă matricială indușă de normă vectorială $\|\cdot\|$:

$$\|A\| := \sup_{\substack{x \in \mathbb{R}^n \\ x \neq 0}} \frac{\|Ax\|}{\|x\|}, \quad \forall A \in M_n(\mathbb{R}) \quad (1)$$

OBSERVAȚII :

$$1) \|A\| = \sup_{\|x\| \neq 1} \|Ax\|, \quad \forall A \in M_n(\mathbb{R}) \quad (2)$$

$$2) \text{ Fie } x = (x_i)_{i=1}^n \in \mathbb{R}^n \text{ și } \|x\|_p = \left(\sum_{i=1}^n |x_i|^p \right)^{\frac{1}{p}}$$

Atunci

$$\|A\|_p := \sup_{\substack{x \in \mathbb{R}^n \\ x \neq 0}} \frac{\|Ax\|_p}{\|x\|_p}, \quad \forall A \in M_n(\mathbb{R}) \quad (3)$$

VECTOR

$$\|x\|_1 := \sum_{i=1}^n |x_i|$$

$$\|x\|_2 := \left(\sum_{i=1}^n |x_i|^2 \right)^{1/2}$$

$$\|x\|_\infty := \max_{i=1, \dots, n} |x_i|$$

MATRICE

$$\|A\|_1 := \max_{j=1, \dots, n} \sum_{i=1}^n |a_{ij}|$$

$$\|A\|_2 := \max_{\substack{2 \\ \lambda \in \sigma(A^T A)}} \lambda$$

$$\|A\|_\infty := \max_{i=1, \dots, n} \sum_{j=1}^n |a_{ij}|$$

DEFINIȚIE (număr de condiționare):

Se număr de condiționare a unei $A \in \mathbb{M}_n(\mathbb{R})$
inversabile

$$k(A) := \|A\| \cdot \|A^{-1}\| \quad (4)$$

unde $\|\cdot\|$ este o normă matricială
indusă de o normă vectorială pe \mathbb{R}^n .

OBSERVATII:

1) În general, $\kappa_p(A) := \|A\|_p \|A^{-1}\|_p$, unde $p \in \{1, 2, \infty\}$.

2) $\kappa(A) \geq 1$

— //

$$\gamma = \|I_n\| = \|A \cdot A^{-1}\| \leq \|A\| \cdot \|A^{-1}\| = \kappa(A) \quad \square$$

3) $\kappa(A)$ foarte mare $\Rightarrow A$ în naivă condiționă;

$\kappa(A)$ "rezonabil" $\Rightarrow A$ în bune condiționă,

4) $\kappa(A) = \kappa(A^{-1})$

5) $\kappa(\alpha A) = \kappa(A)$

DEFINITIE (normă Frobenius):

$\|A\|_F := \left(\sum_{i,j=1}^n |a_{ij}|^2 \right)^{1/2}$ este o normă pe

$M_n(\mathbb{R})$, numită normă Frobenius, ie normă euclidiană pe $\mathbb{R}^n \cong M_n(\mathbb{R})$.

4) ANALIZA STABILITATII SISTEMULUI LINIAR

Analizăm sensitivitatea soluției sistemului liniar

$$\boxed{Ax = b} \quad (1)$$

La variatii ale datelor problemei, ie
variatii ale matricei sistemului, A ,
respectiv variatii ale membrului drept, b ,
- analiza directă a stabilității

TEOREMA 1:

Fie $A \in \mathbb{M}_n(\mathbb{R})$ înversabilă, $\underline{b} \in \mathbb{R}^n \setminus \{0\}$

și $\underline{x}^* = A^{-1}\underline{b}$ soluția exactă a sistemului (1)

Dacă $\underline{x} \in \mathbb{R}^n$ este o soluție numerică pt (1),
atunci

$$\boxed{\frac{1}{\kappa(A)} \frac{\|\underline{b} - A\underline{x}\|}{\|\underline{b}\|} \leq \frac{\|\underline{x}^* - \underline{x}\|}{\|\underline{x}^*\|} \leq \kappa(A) \frac{\|\underline{b} - A\underline{x}\|}{\|\underline{b}\|}} \quad (2)$$

Dem:

$$\bullet A(x^* - x) = Ax^* - Ax = b - Ax \Rightarrow$$

$$|x^* - x| = A^{-1}(b - Ax) \Rightarrow$$

$$|x^* - x| \leq \|A^{-1}\| \cdot \|b - Ax\|$$

} \Rightarrow

$$\bullet Ax^* = b \Rightarrow \|b\| \leq \|A\| \cdot \|x^*\|$$

$$\boxed{\frac{|x^* - x|}{\|x^*\|} \leq \underbrace{(\|A\| \cdot \|A^{-1}\|)}_{= \kappa(A)} \frac{\|b - Ax\|}{\|b\|}}$$

$$\bullet \|b - Ax\| \cdot \|x^*\| = \|Ax^* - Ax\| \cdot \|A^{-1}b\| \leq$$
$$\leq \|A\| \cdot \|x^* - x\| \cdot \|A^{-1}\| \cdot \|b\|$$
$$= \kappa(A) \|x^* - x\| \cdot \|b\| \Rightarrow$$

$$\boxed{\frac{1}{\kappa(A)} \frac{\|b - Ax\|}{\|b\|} \leq \frac{\|x^* - x\|}{\|x^*\|}}$$

□